SIMPLON.CO

JANVIER 2026

Certification Développeur en Intelligence Artificielle

E1 : Gestion des données

PREPARED BY

Aurélien Ruide

PROJET

OrionTrader

Table of Contents

03 Contexte du projet

05 Spécifications techniques

06 Extraction des données

06 Transformation et Préparation des données

05 Stockage et organisation des données

06 API de mise à disposition des données

Contexte du projet

Le projet s'inscrit dans le trading algorithmique sur le Forex, avec un focus sur la paire EUR/USD. Il vise à construire une chaîne de traitement de données automatisée et fiable, capable d'alimenter des analyses quantitatives et des modèles d'aide à la décision pour le trading.

La qualité et la cohérence des données sont essentielles, car les stratégies reposent sur des flux à haute fréquence, des données financières de référence et des indicateurs macro-économiques.

Ces données proviennent de sources hétérogènes et doivent être consolidées pour être exploitables efficacement.

Le projet répond à plusieurs enjeux : automatiser la collecte quotidienne, garantir la traçabilité et la fiabilité, structurer les données selon leur fréquence et préparer des jeux de données pour le trading algorithmique.

Un pipeline ETL avec couches Bronze, Silver et Gold a été mis en place pour assurer un traitement robuste et structuré des données.

Spécifications techniques

L'architecture repose sur un pipeline ETL développé en Python, orchestré par Apache Airflow. Airflow permet d'automatiser et de superviser les traitements, de gérer les dépendances et de reprendre les tâches en cas d'échec. Le pipeline s'exécute quotidiennement selon la disponibilité des données.

Les sources de données sont multiples :

- MetaTrader 5 : cotations intra-day EUR/USD
- Yahoo Finance : données journalières financières
- Sources macro-économiques : indicateurs mensuels ou annuels

Les données sont stockées dans des formats optimisés (Parquet) et organisées en tables dédiées selon leur type et fréquence. Chaque exécution est identifiée et contrôlée pour garantir la cohérence et la qualité, assurant ainsi un socle fiable pour l'analyse et le trading algorithmique.

Extraction des données

L'extraction des données constitue la première étape du pipeline ETL et repose sur une automatisation complète afin de garantir la régularité et la reproductibilité des traitements. Cette phase vise à collecter les données nécessaires à l'analyse des marchés financiers à partir de sources hétérogènes, tout en respectant leurs contraintes techniques et temporelles.

Trois flux d'extraction distincts ont été mis en place, chacun correspondant à une source de données spécifique. Les données de marché sont extraites depuis la plateforme MetaTrader 5 et concernent des cotations intra-day sur la paire EUR/USD, à une granularité de quinze minutes. Ces données sont essentielles pour l'analyse fine des variations de prix et pour les stratégies de trading à court terme.

En complément, des données financières journalières sont récupérées via le service Yahoo Finance. Elles permettent d'apporter un contexte de marché plus large et servent notamment de données de référence pour certaines analyses comparatives ou indicateurs dérivés. Enfin, des données macro-économiques sont extraites à partir de sources institutionnelles, sur une période étendue de plusieurs années. Ces données, disponibles à une fréquence mensuelle ou annuelle, sont utilisées pour intégrer des facteurs macro-économiques susceptibles d'influencer les tendances de marché.

L'ensemble des extractions est paramétrable dynamiquement, notamment en ce qui concerne les plages temporelles. Cette approche permet d'adapter les traitements aux besoins du projet, tout en assurant la cohérence des données collectées. Les extractions sont exécutées en parallèle afin d'optimiser les temps de traitement et de tirer parti de l'indépendance des sources.

À l'issue de cette phase, les données extraites sont stockées sous forme de jeux de données bruts, sans transformation majeure, constituant ainsi la couche Bronze du pipeline. Cette séparation permet de conserver une trace fidèle des données sources et de faciliter les traitements ultérieurs, tout en garantissant la possibilité de rejouer les transformations en cas d'évolution des besoins ou des règles de gestion.

Transformation et Préparation des données

Après l'extraction, les données passent par la couche Silver, dédiée à la transformation et à la préparation. Cette étape est essentielle pour rendre les données analysables et exploitables pour le trading algorithmique.

Le pipeline ETL est conçu autour de trois sources indépendantes :

1. MT5 : données intra-day EUR/USD
2. Yahoo Finance : données journalières financières
3. Documents macro-économiques : données institutionnelles mensuelles ou annuelles

Chaque source suit un processus de transformation distinct, exécuté en parallèle pour optimiser les temps de traitement. Les transformations comprennent :

- Nettoyage et validation : suppression des doublons, gestion des valeurs manquantes, uniformisation des formats.
- Création de features : calcul d'indicateurs et enrichissement des données, par exemple des moyennes mobiles, variations relatives ou ratios financiers.
- Agrégation et snapshot du marché : un jeu de données consolidé ("market snapshot") est généré à partir des trois sources pour offrir une vue complète du marché à un instant donné.

Les transformations ne dupliquent pas les données sources et respectent la fréquence native de chaque flux : M15 pour MT5, Daily pour Yahoo, Monthly/Annual pour les données macro. Les calculs composites sont effectués à l'export (CSV), ce qui rend le pipeline plus flexible et évite d'alourdir la base.

Stockage et organisation des données

La couche Gold du pipeline ETL est dédiée au chargement et à l'organisation des données dans les tables finales. Chaque source dispose de sa propre table, garantissant ainsi une structure claire et la non-duplication des données :

- mt5_eurusd_m15 pour les cotations intra-day
- yahoo_finance_daily pour les données financières journalières
- documents_macro pour les indicateurs macro-économiques
- market_snapshot_m15 pour la consolidation des trois sources

Les données sont stockées en format Parquet, performant pour la lecture et la compression, et chaque exécution du pipeline est identifiée par un ID unique. Cela permet de tracer et reproduire les traitements, tout en facilitant la validation de la qualité des données.

Un mécanisme de validation automatique contrôle la cohérence et la complétude des tables, et des notifications (via Discord) informent l'équipe en cas d'anomalies. Cette approche garantit que toutes les données chargées sont fiables et prêtes à être exploitées pour des analyses et le trading algorithmique.

API de mise à disposition des données

Pour démontrer la maîtrise de l'exposition de données via une API, le projet inclut une API FastAPI permettant d'accéder aux jeux de données transformés et stockés dans la couche Gold du pipeline ETL.

Remarque légale : Les données originales de MetaTrader 5, Yahoo Finance et documents macro-économiques ne peuvent pas être redistribuées, même gratuitement, pour des raisons de propriété et de RGPD. L'API est donc pédagogique et démonstrative, utilisée pour montrer la capacité à créer un service de données fiable et sécurisé.

Objectifs et fonctionnalités

L'API permet :

- L'accès aux tables Gold et aux snapshots de marché.
- Le filtrage des données par dates, symboles ou indicateurs.
- La consultation via des endpoints standardisés et documentés.

Architecture et endpoints

L'API est modulaire, avec core (DB, dépendances), schemas (modèles Pydantic) et routes (Market, Data & Features, Trading Signals).

Quelques endpoints principaux :

- /market/latest : dernier snapshot
- /market/ohlcv/m15 : données OHLCV M15
- /data/features/mt5 : features MT5
- /data/training : dataset complet pour ML
- /signals/high-confidence : signaux haute confiance
- /health : vérifie connexion DB et nombre de lignes

Les réponses sont au format JSON, avec filtrage temporel et pagination. La documentation interactive est disponible via Swagger UI (/docs) et Redoc (/redoc).

Intégration avec le pipeline ETL

L'API accède directement aux tables Gold générées par le pipeline ETL : après chaque exécution, les données transformées sont disponibles pour démonstration, avec validation automatique de la qualité et traçabilité.